



خلاصه پیشنهاد سمینار کارشناسی ارشد

عنوان سمینار: مروری بر سازوکارهای گسترش ژرف برای سامانه‌های ارتباطات بی‌سیم نسل بعد
(Review of Deep Unfolding Mechanisms for Next-Generation Wireless Communication Systems)

1- شرح مساله (با ارجاع به مراجع)

شبکه‌های سیار نسل آینده، از جمله نسل ششم (6G)^۱، با رشد تصاعدی تقاضا برای منابع ناشی از افزایش دستگاه‌های متصل، مواجه هستند. نیازهای کلیدی نسل ششم شامل نرخ داده بالا (یک ترابیت بر ثانیه)، بازده طیفی بالا، اتصال انبوه (مانند دستگاه‌های اینترنت اشیا که ده برابر نسل پنجم هستند) و تأخیر فوق‌العاده کم است. همچنین، ظهور کاربردهای مبتنی بر هوش مصنوعی نیازمند یکپارچه‌سازی هوش مصنوعی و ارتباطات است [۱]، [۲].

روش‌های سنتی ارتباطات بی‌سیم، که اغلب بر اصول بهینه‌سازی تکراری^۲ و تعامد منابع تکیه دارند، اغلب به دلیل پیچیدگی بالا و زمان اجرای طولانی (اغلب ناشی از متغیر بودن پارامترهای محیطی)، برای برآوردن الزامات بی‌سابقه سناریوهای بی‌درنگ در شبکه‌های نسل جدید ناکافی هستند [۱]، [۲]. بسیاری از مسائل حیاتی مانند تخصیص منابع غیرمحدب^۳ هستند و یافتن راه‌حل بهینه سراسری برای آن‌ها دشوار است [۳]، [۴]، [۵]، [۶].

گسترش ژرف^۴ به عنوان یک رویکرد یادگیری عمیق مدل-محور^۵ مطرح می‌شود [۱]. این سازوکار به منظور بهره‌گیری همزمان از مزایای دانش دامنه^۶ الگوریتم‌های بهینه‌سازی کلاسیک و کارایی محاسباتی مدل‌های یادگیری عمیق توسعه یافته است [۱]، [۲]، [۶]. در این سمینار، ضمن معرفی حوزه پژوهشی «گسترش ژرف» بررسی می‌شود که چگونه می‌توان راه‌حل‌هایی تفسیرپذیر، مقیاس‌پذیر و بسیار کارآمد برای چالش‌های لایه فیزیکی و تخصیص منابع در شبکه‌های پیچیده و توزیع‌شده نسل آینده ارائه داد [۱]، [۶].

2- مباحث تحت پوشش سمینار (با ارجاع به مراجع)

تمرکز این تحقیق بر کاربردهای مدل‌های گسترش ژرف در لایه فیزیکی و تخصیص منابع شبکه‌های بی‌سیم بوده و به شرح زیر است:

۱. ساختار عمومی گسترش ژرف:
 - تبدیل الگوریتم‌های تکراری به یک شبکه عصبی با لایه ثابت^۷ [۱]، [۲].
 - استفاده از توابع زیان مناسب برای آموزش پارامترهای یادگیری‌پذیر^۸ [۱].
 - طبقه‌بندی گسترش ژرف در چارچوب یادگیری عمیق مدل-محور [۱].
۲. کاربردهای گسترش ژرف در بهینه‌سازی تخصیص منابع در شبکه‌های بی‌سیم نسل بعد:
 - آشکارسازی سیگنال: از جمله در سیستم‌های Massive MIMO^۹ و OFDM^{۱۰} یا OTFS^{۱۱} [۱].
 - تخمین کانال: به خصوص در سیستم‌های Massive MIMO و mmWave^{۱۲} [۱].

¹ Sixth generation

² Iterative optimization

³ Nonconvex

⁴ Deep unfolding

⁵ Model-driven deep Learning

⁶ Domain knowledge

⁷ Fixed-depth layers

⁸ Trainable parameters

⁹ Massive Multiple-Input Multiple-Output

¹⁰ Orthogonal Frequency-Division Multiplexing

¹¹ Orthogonal Time Frequency and Space

¹² Millimeter wave

- طراحی پیش‌کدگذار: شامل طراحی هیبریدی^{۱۳} و تخصیص توان [۱].
- کدگذاری: شامل کاربرد در کدگشاهای LDPC^{۱۴} و کد قطبی^{۱۵} [۱].
- ۳. تخصیص منابع و بهینه‌سازی:
 - تخصیص توان: به عنوان یک مساله بهینه‌سازی نرخ تجمیعی^{۱۶} یا بازده انرژی [۱]، [۳]، [۶].
 - استفاده از شبکه‌های عصبی گراف^{۱۷} در گسترش ژرف (UWMMSE)^{۱۸}: پارامتری‌سازی وزن‌های شبکه‌های گسترش ژرف با شبکه‌های عصبی گراف برای بهینه‌سازی تخصیص توان توزیع‌شده^{۱۹} [۶].
 - حل مسائل پیچیده: کاربرد در بهینه‌سازی‌های مبتنی بر برنامه‌ریزی کسری^{۲۰} یا ADMM^{۲۱} [۳]، [۴].
- ۴. فناوری‌ها و سناریوهای کلیدی نسل ششم:
 - حسگری و ارتباطات یکپارچه^{۲۲}: کاربرد گسترش ژرف در بهینه‌سازی مشترک توابع حسگری و ارتباطات [۱]، [۲].
 - سطوح هوشمند بازتابنده^{۲۳} (STAR-RIS): استفاده در تخمین کانال و طراحی پیش‌کدگذار برای سیستم‌های MIMO با کمک سطوح هوشمند [۱].
 - دسترسی تصادفی انبوه^{۲۵} و دسترسی چندگانه غیرمتعامد^{۲۶}: حل مسائل آشکارسازی کاربر فعال و تخمین کانال در دسترسی انبوه و تخصیص توان در دسترسی چندگانه متعامد [۲].
 - روش‌های مشترک: مانند آشکارسازی مشترک و تخمین کانال، یا تخمین کانال و طراحی پیش‌کدگذار [۱].

۳- اهمیت موضوع

گسترش ژرف از چند جهت قابل توجه برای پژوهش بیشتر است. مورد اول اهمیت کارایی محاسباتی است که در این خصوص مدل‌های گسترش ژرف در مقایسه با الگوریتم‌های تکراری سنتی (مانند WMMSE^{۲۷}) یا حل‌کننده‌های نرم‌افزاری مانند CVX^{۲۸}، زمان اجرای کوتاه‌تری دارند. به عنوان مثال، در یک مقایسه، UWMMSE زمان پردازش یک نمونه را در حدود ۲ میلی‌ثانیه انجام می‌دهد، در حالی که WMMSE حدود ۱۶ میلی‌ثانیه زمان می‌برد، که این امر گسترش ژرف را برای کاربردهای بلادرنگ در شبکه‌های نسل جدید مناسب می‌سازد. بعلاوه به دلیل تعبیه دانش حوزه در ساختار شبکه، تفسیرپذیری بیشتری نسبت به شبکه‌های عصبی عمومی^{۲۹} ارائه می‌دهد. این رویکرد ساختار یک الگوریتم بهینه‌سازی را حفظ می‌کند و در نتیجه منجر به عملکرد بهتر با نیاز به داده‌های آموزشی کمتر نسبت به مدل‌های کاملاً داده‌محور می‌شود. همچنین استفاده از شبکه‌های عصبی گراف برای پارامتری‌سازی مدل‌های گسترش ژرف (مانند UWMMSE) تضمین می‌کند که این مدل‌ها تغییرناپذیری نسبت به جایگشت^{۳۰} دارند. این خاصیت باعث می‌شود که سیاست‌های تخصیص منابع آموزش‌دیده، بدون نیاز به آموزش مجدد، به توپولوژی‌های جدید شبکه، اندازه‌های مختلف شبکه و تراکم‌های متفاوت تعمیم یابند. درنهایت، معماری گسترش ژرف می‌تواند برای انطباق با توابع مطلوبیت، مانند نرخ تجمیعی یا مجموع مربعات نرخ تغییر کند؛ قابلیت‌ای که در روش‌های صرفاً داده‌محور کمتر دیده می‌شود.

¹³ Hybrid beamforming

¹⁴ Low-Density Parity-Check codes

¹⁵ Polar codes

¹⁶ Sum-rate

¹⁷ Graph neural network

¹⁸ Unfolded Weighted Minimum Mean Squared Error

¹⁹ Distributed power allocation

²⁰ Fractional

²¹ Alternating Direction Method of Multipliers

²² Integrated Sensing And Communication

²³ Reconfigurable intelligent surface

²⁴ Simultaneously Transmitting and Reflecting Reconfigurable Intelligent Surface

²⁵ Multiple Random Access

²⁶ Non-orthogonal multiple access

²⁷ Weighted Minimum Mean Squared Error

²⁸ ابزار بهینه‌سازی محدب در نرم‌افزار متلب

²⁹ Black-box deep neural networks

³⁰ Permutation equivariance

- [1] Sukanya Deka¹, Kuntal Deka, Nhan Thanh Nguyen, Sanjeev Sharma, Vimal Bhatia, and Nandana Rajatheva. 2025. "Comprehensive Review of Deep Unfolding Techniques for Next-Generation Wireless Communication Systems" Arxiv.
<https://doi.org/10.48550/arXiv.2502.05952>
- [2] Wei Chen, Yuanwei Liu, Hamid Jafarkhani, Yonina C. Eldar, Peiying Zhu, Khaled B Letaief. 2024. "Signal Processing and Learning for Next Generation Multiple Access in 6G" IEEE Journal of Selected Topics in Signal Processing, vol. 2, no. 7.
<https://doi.org/10.48550/arXiv.2309.00559>
- [3] Abuzar B. M. Adam, Mohammed A. M. Elhassan, Elhadj Moustapha Diallo. 2024. "Optimizing Wireless Networks with Deep Unfolding: Comparative Study on Two Deep Unfolding Mechanisms" Arxiv.
<https://doi.org/10.48550/arXiv.2403.18930>
- [4] Siya Chen, Chee Wei Tan. 2024. "Neural Sum Rate Maximization for AI-Native Wireless Networks: Alternating Direction Method of Multipliers Framework and Algorithm Unrolling" NetAISys '24: Proceedings of the 2nd International Workshop on Networked AI Systems.
<https://doi.org/10.1145/3662004.366355>
- [5] Siya Chen, Chee Wei Tan, Xiangping Zhai, and H. Vincent Poor. 2025. "OpenRANet: Neuralized Spectrum Access by Joint Subcarrier and Power Allocation with Optimization-based Deep Learning" Arxiv.
<https://doi.org/10.48550/arXiv.2409.12964>
- [6] Arindam Chowdhury, Gunjan Verma, Chirag Rao, Ananthram Swami, and Santiago Segarra. 2021. "Unfolding WMMSE using Graph Neural Networks for Efficient Power Allocation" IEEE Transactions on Wireless Communications, vol. 20, no. 9.
<https://doi.org/10.48550/arXiv.2009.10812>
- [7] Zhiyang Wang, Mark Eisen, Alejandro Ribeiro. 2022. "Learning Decentralized Wireless Resource Allocations with Graph Neural Networks" IEEE Transactions on Signal Processing vol. 70.
<https://doi.org/10.1109/TSP.2022.3163626>
- [8] Wei Huo, Huiwen Yang, Nachuan Yang, Zhaohua Yang, Jiuzhou Zhang, Fuhai Nan, Xingzhou Chen, Yifan Mao, Suyang Hu, Pengyu Wang, Xuanyu Zheng, Mingming Zhao, Ling Shi. 2024. "Recent Advances in Data-driven Intelligent Control for Wireless Communication: A Comprehensive Survey" Arxiv.
<https://doi.org/10.48550/arXiv.2408.02943>